面向 ORCA 的证据约束闭环自主量子化学计算

单决策循环与 Code as Tools 的设计、实现及跨版本证据

摘要

大语言模型能够生成量子化学输入与任务代码，但从自然语言需求到可信科学结论仍受到目标歧义、计算失败、证据遗漏和成本失控的共同制约。本文以 BG6022-V4 为核心，并补充 v2/v3 的历史量化证据，结合 AutoDFT 的闭环规划与结果反思思路，以及自主多参考量子化学研究对工作流决策和电子态识别的分析，提出并实现面向 ORCA 的证据约束研究原型。系统采用唯一决策主循环，将用户目标与最低证据要求独立于执行计划保存，使用固定通用工具组织现场生成的 Python 和 ORCA 输入，并通过统一执行入口、隔离环境、累计预算与不可变产物记录约束实际操作。报告严格区分执行正常结束、科学检查通过和完整目标完成。v2 两条人工批准的成功链保留了六个真实计算节点与完整频率证据；v3 固定科学矩阵为 11/11，含真实模型参与的核心基准为 18/18 情境、37 次调用和 147,938 tokens，但任务范围与评分口径均有限。v4 早期乙醇案例完成一次自主优化与频率计算，独立开发审计支持所得构型为局部谐振极小值；有限正己烷案例完成四个候选的单点能量比较，但交付包含开发者元数据协助。最新冻结版本的七项跨任务测试产生 53 次模型调用、1,048,678 tokens 和 8 次真实 ORCA 启动，其中 7 次正常结束，完整目标完成数仍为 0/7。失败主要分布于来源规范化、逐目标条件传递、修复路线继承、上下文容量和错误证据发现。结果说明，受控执行底座与个别科学案例已有真实证据，通用自主可靠性尚未建立。本文据此给出可复核的能力边界、失败分类和后续验证方案，为闭环量子化学 Agent 的工程评价提供实践依据。

关键词：自主量子化学；大语言模型；ORCA；闭环规划；代码作为工具；科学证据；有界执行

报告范围。2026 年 10 月 21 日（Asia/Hong_Kong）扩充 BG6022-v2/v3 历史证据。v4 的正式实验仍固定为原稿选择的 `refreeze-3` 批次（产品候选 `89d55708`，原检索 HEAD `def9e31d`），不随本次报告提交重新计量。v78 离线修复已另行提交于 `2e872a18`，不据此升级历史实验结论。本次仅补充历史记录与图表，未新增模型测试或 ORCA 计算。

1 引言

电子结构计算已经成为研究分子结构、反应性与光谱性质的重要手段。密度泛函理论（density functional theory, DFT）通过电子密度描述基态多电子体系，Kohn–Sham 方案则将其转化为可实际求解的自洽场问题 [1, 2]。现代量子化学软件能够执行丰富的计算，但科学问题与软件操作之间仍有显著距离：研究者需要确定电荷与多重度、选择方法和基组、生成合理结构、识别收敛问题，并判断输出是否真正回答了最初的问题。

这一距离并非仅靠自动写入输入文件就能消除。例如，几何优化正常结束，并不自动证明所得结构为极小值；一个能量值能够从文本中提取，也不证明它与所需的构象、溶剂或电子态一致；脚本完成四个候选的计算，也不能据此宣称找到了整个构象空间的最低能量。对于多参考激发态，活性空间和电子态身份又构成比程序退出码更严格的科学要求。因此，自主计算系统需要同时处理决策、执行和结论资格三个层面。

大语言模型提供了一种将自然语言、软件文档与程序生成连接起来的方式。ReAct 将推理与外部行动交替组织，Toolformer 探索工具调用的学习，Reflexion 利用反馈改善后续行为 [3–5]。ChemCrow 与 Coscientist 则展示了语言模型结合化学工具和实验操作的可能性 [6, 7]。这些研究为自主科学计算提供了启发，也提出了一个必须正面回答的问题：模型能够执行操作时，什么证据才足以支持它交付科学结论？

本文以 BG6022-V4 为主要设计对象，并补充 v2/v3 中可以追溯到原始计算和评测记录的量化成果。v4 选择 ORCA 作为计算核心，以 ORCA Python Interface（OPI）作为主要适配底座[8–10]，将现场生成代码置于受管理工具边界之内。AutoDFT 是本文闭环方法的重要参照，多参考自主计算论文则为任务覆盖、方法决策和正确性评价提供了更严格的参照 [11, 12]。两篇论文的共同启发是：自主性需要在中间结果出现后继续发挥作用，而科学正确性必须接受任务相关的独立审查。

本文的贡献是一个可审查的工程实现与评价报告。第一，给出单决策循环、目标独立和统一执行责任链的系统设计；第二，通过分层结果状态与不可变证据避免把运行成功直接写成科学成功；第三，结合 v2 的已批准计算链、v3 的冻结有限基准和 v4 的生成代码评测，呈现各版本已取得的成果与尚存缺口。本文不主张新的电子结构方法，也不以不同任务集之间的数字比较证明系统优越性。

2 相关工作与研究定位

2.1 传统计算自动化与语言模型工具调用

量子化学和材料计算在语言模型出现之前已经具有成熟的自动化基础。ASE 提供跨计算程序的原子体系接口；AiiDA 强调工作流执行与数据来源；Atomate2 组织模块化材料工作流；cclib 则提供计算化学输出的统一解析能力 [13–16]。这些系统具有各自的动态控制与恢复机制，不能简单概括为完全静态的批处理。其共同价值在于把可重复操作、软件适配和数据组织从个别计算中提取出来。

语言模型的增量作用主要是解释开放需求、在候选行动之间作选择、生成任务特定代码，并根据新证据调整路线。工具增强不意味着每种科学任务都需要一个新工具，也不意味着所有判断都应交给语言模型。本文采取职责分配：模型提出方案，程序验证权限、依赖与资源，并根据现有科学检查确定可发布的结果。化学知识、算法实现和执行许可由此具有不同来源和不同权威。

2.2 AutoDFT：成功与失败都进入闭环

AutoDFT 将战略规划、即时参数规划、执行、监控、恢复、步骤反思和后处理组织为七角色闭环；其 VASPBench 含 34 个任务、9 类计算。原文表 1 中，GPT-5.2 完整系统完成 32/34 (94.1%)，开环与规则基线分别为 28/34 和 23/34。另有 20 个材料的性质评价，误差在成功计算上相对数据库参考统计 [11]。这些结果对应论文自己的 VASP 环境和任务定义，各配置每任务仅运行一次。

对本项目而言，最有用的设计思想是让成功结果也触发下一步决策：新的结构、谱学特征或精度缺口可能要求补算，而不是只在程序崩溃后才调用模型。本文将这种反馈原则放入一个协调者，分别实现规划、工具执行和证据评价职责。角色数不是闭环性的充分条件，单协调者同样需要证明结果确实影响后续行为。

2.3 自主多参考计算：覆盖率与已覆盖子集精度

Lee 与 Rondinelli 研究使用 ORCA 执行多参考计算的自主 Agent，采用 CASSCF/SC-NEVPT2 与 aug-cc-pVTZ 基组。其 558 个 QUESTDB 垂直跃迁目标中，基线、决策阶梯和完整信息复制设置分别覆盖 139、246、378 个目标，覆盖率为 24.9%、44.1%、67.7%；对应已确认电子态子集的 MAE 为 0.373、0.339、0.023 eV[12]。这些误差的分母随覆盖子集变化，完整信息复制也具有更强的先验输入，不能解释为所有目标上的通用自主精度。

该研究提示，执行协议正确与电子态身份正确是不同问题。CASSCF 需要明确活性空间，NEVPT2 在多参考波函数基础上补充动态电子相关 [17, 18]；AVAS 等既有方法为自动构建活性轨道提供专业算法基础 [19]。QUESTDB 提供高精度激发能参照，也使态归属和方法条件成为可检验的评价对象 [20]。本项目目前没有真实验收证据支持自主 CASSCF、NEVPT2 或活性空间选择，因此将这些问题作为未来科学契约扩展，而非现有能力。

表 1 三项研究的任务与评价边界。表中差异为架构定位，不构成共同基准上的性能排名。

维度	AutoDFT	自主多参考研究	本项目
主要对象	周期材料与 VASP 任务	分子多参考垂直跃迁	ORCA 分子计算与已有证据分析
决策组织	多角色分层闭环	自主 Agent 与决策指导	一个协调者与通用 Tool
核心困难	运行恢复和中间物理反馈	活性空间、收敛与态身份	目标条件一致性、受控代码与证据交付
主要评价	任务完成与性质误差	覆盖率和已覆盖态误差	执行、科学检查、目标完成分别报告
可比限制	软件、硬件与任务定义不同	提示信息量和覆盖分母不同	当前缺少完整重复与正式参考矩阵

3 科学背景与评价定义

3.1 方法选择与科学问题的条件依赖

固定核构型下，Kohn–Sham DFT 的电子能泛函可写为

$$E[n] = T_{\mathrm{s}}[n] + \int v_{\mathrm{ext}}(\boldsymbol{r}) n(\boldsymbol{r})\, \mathrm{d}\boldsymbol{r} + E_{\mathrm{H}}[n] + E_{\mathrm{xc}}[n]. \tag{1}$$

分子势能还需加上核间排斥能。交换相关近似、基组、几何和环境共同决定具体计算。PBE、Becke 杂化方案与 LYP 相关泛函提供不同近似选择；def2 基组和 D3 色散修正进一步说明方法名称之外仍有必须明确记录的设置 [21–25]。本文引用这些方法作为选择空间与历史案例背景，不表示每一项都已纳入生产资格或最新评测。

激发态需要区别于基态能量。含时密度泛函理论（TDDFT）的理论基础来自 Runge–Gross 研究 [26]；所需态数、能量、振子强度和态身份均可能影响任务验收。环境比较同样需要明确连续介质模型、几何是否固定以及能量差的物理定义，CPCM 是相关方法之一 [27]。模型可以建议这些选项，但最终报告必须披露实际执行条件，并保持用户明确要求的物理量。

构象搜索可先使用较低成本的方法提出候选。GFN2-xTB 和 CREST 展示了低成本势能描述与构象集合搜索的研究基础 [28, 29]。本文的正己烷历史案例实际使用 RDKit/MMFF 候选和 DFT 单点，不能因为引用这些文献就声称项目使用或验证了 xTB/CREST。方法背景与本项目实际运行记录在全文中分别处理。

3.2 执行、科学检查与目标完成

令第 i 个实际尝试的运行事实为 X_i，第 k 个输出的科学检查为 S_{ik}，第 j 个用户目标是否满足为 G_j。至少需要区分

$$X_i = \text{正常结束}, \qquad S_{ik} = \text{已通过规定检查}, \qquad G_j = \text{证据满足目标要求}. \tag{2}$$

三者不是同义状态。正常结束可以产生未经检查的观察；科学检查也只在所声明的适用范围内成立。一个正确单点能量无法替代用户要求的优化自由能或完整扫描图。

报告层面的完整任务判定要求所有必需目标均有足够证据，且必需交付项齐备：

$$C_{\text{task}} = \left(\bigwedge_{j \in \mathcal{G}_{\text{required}}} G_j \right) \wedge D_{\text{required}}. \tag{3}$$

式 (3) 是评价语义的概括，不表示所有科学问题都具有同一固定检查清单。未注册性质可作为带来源与验证说明的观察交付；是否足以满足目标仍取决于原请求的最低证据要求。

对参考能量评价，覆盖率与误差应共同报告：

$$\text{Coverage} = \frac{N_{\text{matched}}}{N_{\text{target}}}, \qquad \text{MAE}_{\text{matched}} = \frac{1}{N_{\text{matched}}} \sum_{i \in \mathcal{M}} |E_i - E_i^{\text{ref}}|. \tag{4}$$

其中 $\mathcal{M}$ 只包含可确认对应关系的目标。本文未为最新七题运行独立数值参考，不报告不存在的 MAE，也不以没有错误数值发布代替完整任务成功。

4 系统方法

4.1 七对象模型与唯一决策主循环

项目将长期领域对象限制为 Request、Plan、Step、Tool、Run、Result 和 Artifact。尝试、检查项、代码引用及内部调用回执等作为局部类型附着其上，避免同一事实在多个独立生命周期中重复维护。[E1,E2]

表 2 七个领域对象及其在可信计算中的作用。

对象	主要内容	约束作用
Request	原始需求、对象、条件、来源、目标及最低证据	目标不由计划修订隐式降低
Plan	步骤依赖与目标到证据的路线	只选择实现路径，不拥有改写需求的权力
Step	工具参数、代码或输入版本、前置条件	绑定可复核的实际操作
Tool	schema、影响、校验、产物和执行实现	作为访问与执行边界
Run	固定配置、许可快照、尝试、预算与执行句柄	同一 Run 仅有一个协调者
Result	运行事实、逐输出检查、观察、目标满足与诊断	避免混淆操作成功和科学资格
Artifact	输入、脚本、几何、日志与报告及 hash	保留初始数据、历次尝试和来源

图 1 概括决策与执行的关系。主循环在得到新 Result 后先更新目标和证据缺口，再选择下一动作。失败可能要求修复输入；成功可能暴露精度或覆盖不足；已有文件也可能直接支持分析而无须重算。该组织不预设优化、频率、单点的固定顺序，Plan 根据实际目标组合 Step。

4.2 Code as Tools 与统一 ORCA 责任链

Code as Tools 将任务特定算法放入可审查的代码产物，而不是为每个科学问题增加一个专用求解 Tool。模型可以生成 Python，用于几何操作、有限候选筛选、数据分析或绘图；也可以生

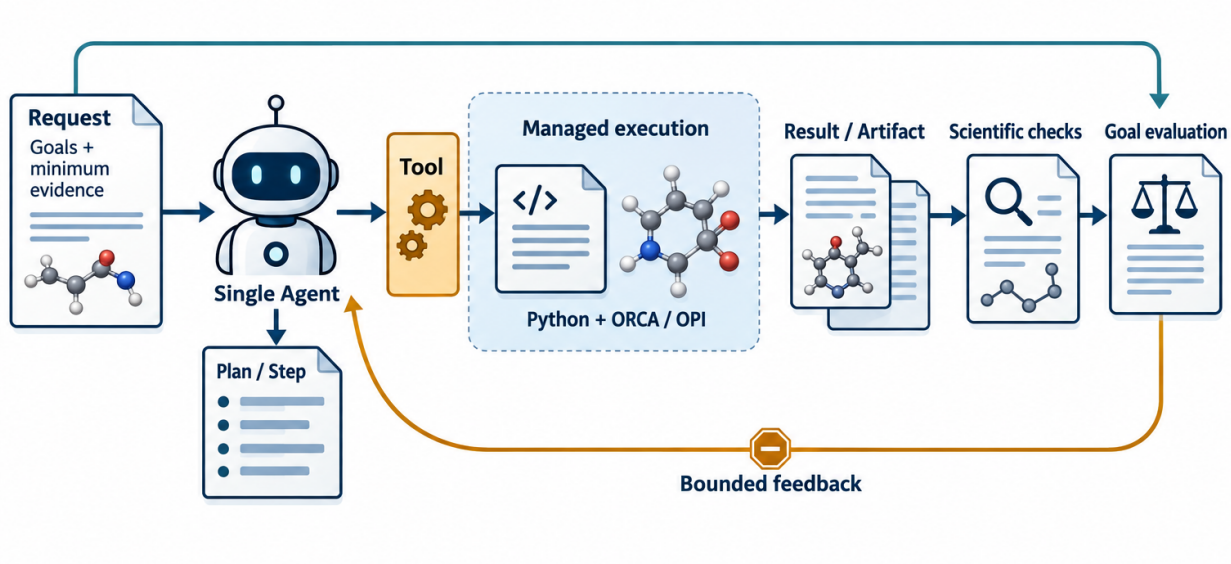


图 1 证据约束闭环的概念示意。唯一 Agent 提出 Plan/Step，经 Tool 进入受管理执行；Result/Artifact 接受科学检查和目标评价后形成有界反馈。Request 中的原始目标直接约束评价。图由 GPT Image 辅助生成，仅说明方法关系，不承载实验数值，也不构成隔离或科学正确性的验证证据；Run 的配置和累计账本未在示意图中展开。

成原生 ORCA 输入。OPI 输入、原生输入和薄 SDK 内部请求最终复用受管理 ORCA 执行入口。[E2,E3]

薄 SDK 的职责是请求一次受控科学计算、返回执行回执和产物引用，不隐藏构象搜索、势能扫描或其他任务求解算法。这样可以检查某项成果究竟来自现场代码、既有解析器还是开发者提供的算法。通用工具目录、参数 schema、校验和输出声明来自相同工具定义，避免模型看到的接口与真正执行的接口分离。

代码被允许访问任务输入副本、必要运行库、任务写目录和受控通信接口。访问网络、任意 shell、产品源码及执行许可均不属于生成代码的权限。程序校验决定动作是否可执行；模型或脚本输出的“通过”字段不能替代生产科学检查。

4.3 目标条件、来源与修复语义

Request 既保留原文，也记录条件的来源：用户明确要求、默认、继承、推断或自动选择。不同目标可以具有不同环境或电子态，例如同一初始几何的气相与水中能量比较。将这些条件压缩成一个全局设置可能改变科学问题，因此实际执行需要按目标、体系和请求的既定优先级读取条件。

计划修复也必须保持目标身份。一个步骤因 Python 语法或 ORCA 关键词错误而重写时，未改变的目标路线应继续继承；修复不能通过删除原目标来获得形式上的完成。与此同时，显式修改后的完整计划仍需核对依赖和科学条件。最新开发修复针对这类跨层不一致进行统一处理，其后续真实自主表现需要相应冻结实验，本文不在本次历史扩充中重新评价。[E9]

来源校验的目的在于证明值与用户原意相符，而不是要求模型重复抄写整段文本。短引文、原文片段和规范化值之间需要统一表示与映射。无来源、跨消息错绑或明确冲突仍应拒绝；准确短引文作为同一来源的不同表示时，则不应被机械地判为冲突。这一区分直接来自最新真实失败，而不是抽象的提示工程偏好。

4.4 不可变证据与开放观察

每次尝试单独保存输入、脚本、标准输出、错误日志和相关产物，初始几何及历史尝试不被覆盖。外部只读引用在消费前核对 hash。读取与执行分离：缺少 JSON 或转换产物时，只读查询报告缺项；转换、分析或重算通过显式工具操作发起。[E1,E3]

生产解析和科学检查沿用已有责任链。生成代码可以从原始输出提取新性质，形成通用观察，但不会由此自动获得 `QualifiedOutput`。这种区分允许开放分析，又保持“看见一个字段”和“科学意义被验证”之间的边界。证据索引使原始文件可发现、可有界查询，而不是要求所有内容一次进入模型上下文。该做法与科学数据可发现和可复用的原则相呼应 [30]，但是否达到完整 FAIR 水平仍需要单独评价。

4.5 隔离、资源与累计预算

项目本地基准为 4 核、整个计算进程树 1024 MiB 内存、环境计算并发 1，ORCA MaxCore 为每进程 192 MiB。MaxCore 只是 ORCA 内部内存设置，不能替代进程树总内存限制。Linux 后端将任务 Python 及内部 ORCA/MPI 放入同一容器 cgroup，并沿用原环境租约；Windows 和 Linux 路径显式选择并冻结，失败不触发无约束后端回退。[E3]

预算包括模型调用、代码重试、计划修订、内部科学计算和产物用量。对任一预算维度 k，令限额为 B_k，累计已用为 U_k，新动作预约为 r_k，执行前至少要求

$$U_k + r_k \le B_k. \tag{5}$$

内部子计算的实际消耗累加到父 Run；暂停、恢复或换标识不清零。执行状态未知时，先对账并保守占用资源，避免重复启动。成本采样具有可见性限制，因而报告保留“已知值”“上界”和“观测下界”的区别。

固定 Linux 环境已测试无网络、只读根文件系统、受控 UID、seccomp 与移除 capabilities 等边界。[E3] 这些是特定软件与宿主组合的实际证据，不能推导为任意环境上的安全证明；每 Attempt 磁盘硬配额等限制也仍需披露。

5 实现与实验设计

5.1 实现映射与冻结环境

实现主要位于 `src/orca_agent/`。主循环和提案处理负责决策编排；语义与条件模块负责 Request 规范化及适用性；工具与受管理执行模块负责边界检查和 ORCA 启动；上下文与产物索引模块负责有界反馈。本文描述的是这些职责的现有实现，不以模块数量或代码行数作为能力指标。

ORCA 的学术使用许可、OPI 的发行和依赖选择均以项目环境验收及各软件自身条款为准。文献引用 ORCA 6 版本论文不等于实际运行 6.0，本文已将版本论文与实际 6.1.1 分开标明。OPI 的正式论文及官方版本文档用于说明接口来源 [10, 31]。

5.2 证据分层与样本构成

实验资料分为四层：离线测试验证程序契约；开发者真实探针验证计算与隔离入口；真实模型开发案例展示特定路线；冻结跨任务评测衡量完整自主交付。不同层次各有证据价值，不能合并为一个成功率。历史补充还区分 v2 的人工批准与离线科学重解析、v3 的确定性科学矩阵，以

表 3 已归档本地 Linux 底座环境。版本和资源来自执行底座验收；它们不是本次报告重新安装或测得的结果。[E3]

项目	固定配置或版本
Linux Python / OPI	CPython 3.11.2；`orca-pi==2.0.0`
ORCA / MPI	ORCA 6.1.1 Linux x86-64；Open MPI 4.1.8
容器环境	Docker Desktop 4.95.0；Engine 29.8.2；cgroup v2
宿主路径	Windows / WSL2 本地 Linux 容器
并发与内存	计算并发 1；4 核；1024 MiB；零 swap
ORCA 设置	MaxCore 192 MiB/进程
最新正式模型	冻结记录标识 DeepSeek Flash / `thinking_low`
最新正式期限	单 ORCA 900 s；父 Python 1200 s；Run 7200 s
最新反馈限制	停止后收集 180 s；输入上下文 64000 上限

及包含真实模型语义与回答环节的脚本化对话基准。本文使用已归档记录作回顾性分析，本次写作未补跑实验。

最新冻结批次沿用 T1–T5 与 H1/H2 原题，每题一次正式尝试，种子为 1701。T1 为乙醇优化与频率，T2 为正己烷构象，T3 为正丁烷扫描，T4 为丙酮五个激发态，T5 为气相与水环境比较，H1 为 HCN 核磁屏蔽，H2 为甲醛极化率旋转比较。H1/H2 在后续批次已被暴露，应视为回归题，不能继续称为独立未见任务。

运行期间冻结产品、提示、配置和评估资产，不注入解题代码，也不在失败后另建 Run 挑选成功。原有更大测试矩阵仅表示允许的总上限，尚未实际运行完整重复、独立参考与控制计算。因此，本文报告观察到的任务结果，避免把少量且反复暴露的题目解释为总体泛化分布。

5.3 评价问题与可复核性

实验围绕四个问题：统一入口能否实际启动受控 ORCA；模型能否产生有科学意义的任务路线；执行结果能否转化为完整目标交付；失败是否有可追溯且未改写的原始事实。量化图的数据保存在 `experiment-data.json`，使用 `make_figures.py` 直接绘制。GPT Image 仅生成图 1 的概念示意，其余图形的数字均来自项目记录。

附录给出证据索引和源码阅读时点。记录目录中的开发阶段名仅用于识别历史实验，不作为产品运行状态。已有用户改动保持原状，报告不会通过更新文字将旧失败升级为成功。

6 结果

6.1 受控执行底座与早期自主正例

本地 Linux 执行底座最终四组共覆盖 21 个不同真实用例，累计实际 ORCA 启动 8 次，没有真实模型调用。[E3] 固定水分子 RHF/STO-3G 单点和严格优化能量分别为 $-74.96299161531729\,E_\mathrm{h}$ 与 $-74.96590119219361\,E_\mathrm{h}$。这些结果说明指定入口可以运行和收集真实计算；未做频率检查的优化不能据此认定为极小值。

早期 `live035` 则提供真实模型自主正例：模型从乙醇请求生成结构、自选 B3LYP/def2-SVP，采用气相、零电荷、单重态的 RKS 路线，完成一次 Python 和一次四进程 ORCA 计算。[E4] 模型

记录为 v55 / `deepseek-v4-pro`、`thinking_low`，共 17 次 HTTP 调用和 224,492 tokens。其冻结版本和模型均与最新七题不同。

表 4 乙醇历史自主案例的独立开发审计。数值对应一个构型，不能推广为全局构象结论。[E4]

检查内容	结果
最终电子能	$-154.828249797040\,E_\mathrm{h}$
原子数 / 全部模式数	9 / 27
模式分布	6 个投影零模式，21 个正振动模式
最低正频率 / 最高频率	276.1200 / 3804.5901 cm^{-1}
几何独立核验最大差	6.91×10^{-9} Å
Hessian 独立重建频谱最大差	2.1624×10^{-4} cm^{-1}
收敛检查	五项优化阈值、SCF 与 27 个 CP-SCF 扰动通过
历史 Run 判定	`completed / complete`，两个目标满足
生产结果资格	两项观察为 `unverified`；`QualifiedOutput` 为空

独立开发审计支持该构型在所用方法下为局部谐振极小值。生产观察的资格没有被事后改写，审计前后 201 个原始 Run 文件的 hash 保持不变。首次实际执行前的草稿修改不属于运行失败后的自主修复，本例也不提供多次重复可靠性证据。这一正例说明一条具体自主路径曾经成立，同时说明“开发者复核成立”和“生产科学资格已覆盖”需要分别表达。

6.2 有限正己烷候选比较

正己烷开发案例生成并保存 12 个候选，在 4 次 ORCA 限额内选择其中 4 个进行 B3LYP/6-31G、RKS、气相、零电荷和单重态单点计算。[E5] 相对能量按照

$$\Delta E_i = (E_i - \min_{j \in \mathcal{S}} E_j) \times 2625.4996394799\ \mathrm{kJ\,mol^{-1}}/E_\mathrm{h} \tag{6}$$

计算，其中 $\mathcal{S}$ 只含已评估的四个候选。图 2 使这一有限范围清晰可见。

最终记录为 8/8 目标完成，但交付经过开发者元数据协助和多次授权续作，不能计入无人干预冻结评测。原 `live006` 累计 38 次 HTTP、854,725 tokens 和 4 次 ORCA；更大开发总账包含该 Run，不应重复相加。全部候选互异和 MMFF 收敛也未充分验证。因此，本例的证据强度是有限候选单点比较和代码执行链可用，而不是构象全局搜索已经可靠完成。

6.3 四个冻结候选的跨任务结果

表 5 与图 3 保留四批完整历史。四批均为同七题各一次，但候选版本发生改变，任务也已暴露，因此合计仅描述开发历史。[E6–E8]

四批真实记录证明执行数量与完整交付没有同步增长。它们也表明失败不仅发生在量子化学程序内部：若请求规范化或目标条件消费不一致，任务会在计算前停止；若证据发现和上下文组织失败，真实计算即使完成也不能转化为科学交付。

6.4 最新七题的执行与目标缺口

最新正式批次固定 `simplified-1` 与提示 v77。53 次模型调用使用 1,048,678 tokens，8 次 ORCA 实际启动、7 次正常结束；完整目标为 0/7，独立逐题审查均因必需项缺失判为失败。[E8] 表 6 和图 4 给出分布。

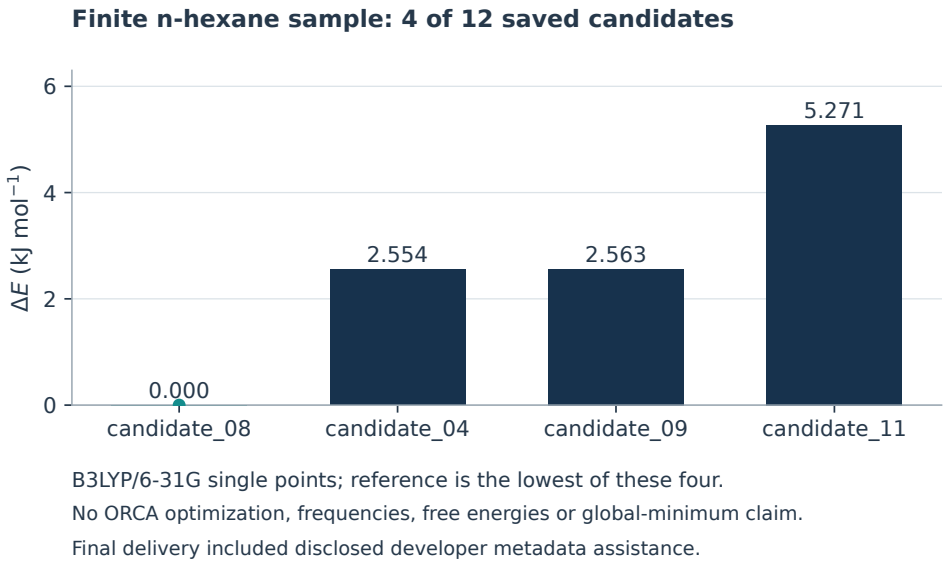


图 2 正己烷四个已评估候选的单点相对电子能。候选 08、04、09、11 分别为 0、2.554112、2.563181、5.270516 kJ mol^{-1}。另 8 个候选未进行 ORCA 计算；未做 ORCA 优化或频率，不能据此报告全局最低、极小值或自由能排序。数据来自含开发者元数据协助的历史案例。[E5]

表 5 正式跨任务评测历史。每一行对应不同冻结候选，不能视为同一系统的四次独立重复。

批次	模型调用	tokens	ORCA 启动	完整目标
初轮	42	604,825	0	0/7
重冻结 1	88	1,748,183	2	0/7
重冻结 2	111	2,110,705	3	0/7
重冻结 3	53	1,048,678	8	0/7
历史合计	294	5,512,391	13	0/28 次尝试

表 6 最新正式批次的逐任务结果。正常结束数以实际 ORCA 调用为单位，完整目标以任务为单位。

任务	调用	tokens	启动/正常	主要缺口或停止原因
T1	3	39,588	0/0	短引文与片段冲突、值来源规则不一致；未形成计划
T2	3	36,542	0/0	封装错误、能量措辞与几何标签门槛；未形成计划
T3	14	338,495	6/6	缺末点、曲线和加密决定；路线丢失与上下文超限
T4	16	343,256	1/0	原生关键词错误；根因被解析异常遮蔽，后续超限
T5	3	34,966	0/0	逐目标条件未贯通后续路由，提前停止
H1	11	207,725	1/1	原始屏蔽张量存在，提取、核对与交付未完成
H2	3	48,106	0/0	引文与固定几何标签纠错耗尽
合计	53	1,048,678	8/7	七项均为失败或部分完成

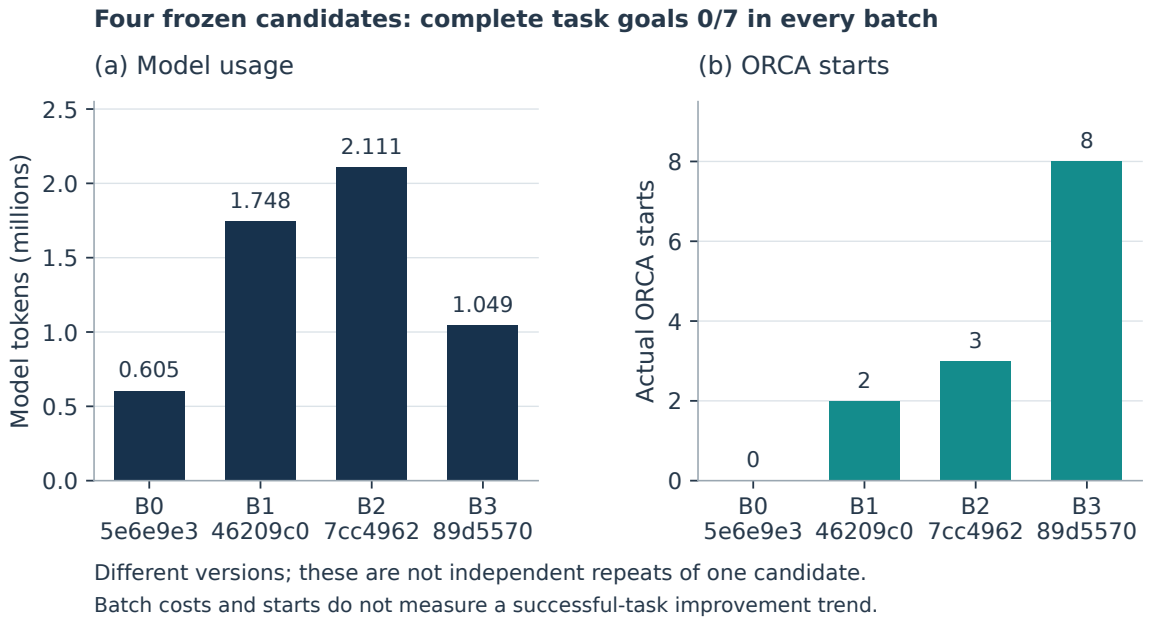


图 3 四个不同候选的模型 token 用量与实际 ORCA 启动数。ORCA 启动更多表明部分执行路径被推进，但各批完整目标均为 0/7，不能将其解释为端到端成功率提升。批次间模型、提示与实现存在变化，不作因果性能比较。

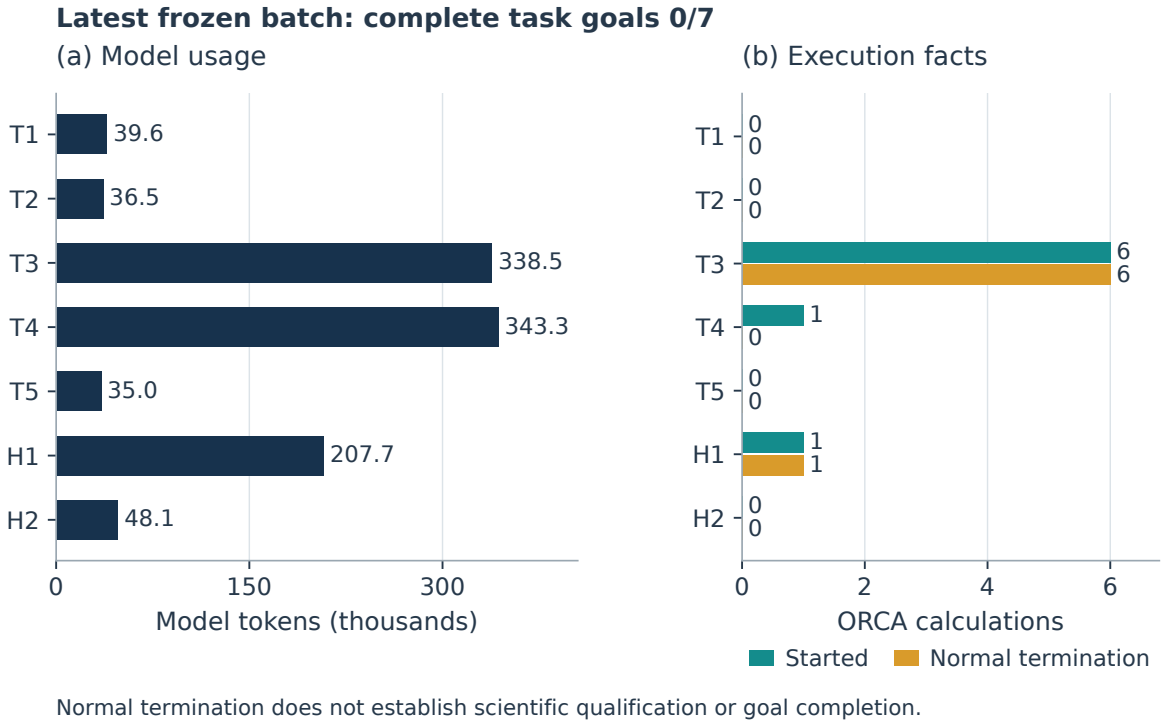


图 4 最新七题的模型 token 分布与 ORCA 调用事实。T3、T4、H1 消耗了主要模型上下文；七次正常结束集中在 T3 的六次计算与 H1 的一次计算。图中的计算完成事实不赋予整题科学通过资格。[E8]

T3 中，首次 Python 由于 ORCA 的 `%maxcore` 与字符串格式化冲突失败；模型在同一逻辑步骤完成一次代码修复，此后六次内部 ORCA 正常结束并归档。这是运行错误后自主修复与多次内部计算的真实证据。可是脚本自设的时间窗口跳过 $+180°$，并未用尽冻结父期限；曲线和后续加密决定缺失，实际角与目标角也未独立重算。七条观察的来源绑定通过不能替代扫描约束和完整目标检查。

H1 中，最终原生输入的 `NMR` 计算正常结束，输出含 C、N、H 三核总屏蔽张量与各向同性摘要，原稿、执行稿和归档文件均有 hash 核对。然而计算返回后构建模型上下文失败，后续提取、核对和交付没有证据。T4 则在 ORCA 输入阶段拒绝简单关键词行中的 `TDDFT`，外层 Python 随后出现解析异常；多次读取未使模型及时获得内部错误窗口。不能将此描述成模型已经看到根因却拒绝修复。

6.5 成本、归档与离线验证

最新批次按冻结价表最高档计算的已知模型费用上界为 0.5735982 USD，未查询供应商实际账单。[E8] 七次执行驱动区间累计 2706.749 s；已记录计算经过时间为 1178.063 s，CPU 为 3581.138406 s，后两者因采样不完整作为观测下界报告。token 数不等于独立科学信息量，尤其多次读取、失败反馈和重复协议可能重复消耗上下文。

证据索引覆盖 1504 个源文件，公开包含 1238 个文件、15,254,745 字节，超大原件保留于本地且可发现。14 次前后冻结核验匹配，既有三批账本快照未变，没有未知结算或预算超支记录。上述冻结核对支持实验身份和账本连续性，不等于重新执行攻击测试或重验所有历史科学文件。

离线测试也需要按版本解释。历史某一候选曾取得 2579 通过、0 失败、3 跳过的完整离线回归，其后真实七题仍未完成。[E7] 最新正式批次前，另一轮统一检查为 3003 通过、19 失败、3 跳过，修复后有定向检查；后续完整回归中止，第三轮在用户要求转向真实测试后于约 28% 结束。[E8] 因此本文不以这些历史记录声称后续工作树全量回归通过，更不将离线通过数当作自主科学任务成功数。

6.6 v2：真实计算链与可重解析的科学证据

历史补充首先考察 v2 的两条已完成计算链：水与乙醇分别执行气相、零电荷、单重态的 r^2SCAN-3c/TightSCF 优化、频率和单点，使用 ORCA 6.1.1。r^2SCAN-3c 是具有专门参数与组合校正的复合方法 [32]，不应直接与 v4 的 B3LYP/def2-SVP 绝对能量比较精度。两条链经过逐节点人工批准；后续 P6 使用冻结的 P5 输出进行离线科学重解析，并未重新启动计算。[H2]

图 5 直接绘制原始优化输出。每个点是相应优化周期中最后一个 `FINAL SINGLE POINT ENERGY`，零点取收敛后的末次能量评价；这一次末次评价不额外计作优化周期。水和乙醇分别经历 4、11 个周期。能量降低表示从给定初始构型到该终态的变化，既不是相对实验的误差，也不是不同版本之间的算法收益。

频率证据分别包含 3、21 个正振动模式，历史科学策略据此给出 `supported_within_policy` 的局部极小值支持。定义 $\Delta E = E_{\mathrm{SP}} - E_{\mathrm{Opt,final}}$，两者的有符号能量差分别为 $-2.0 \times 10^{-11}\,E_{\mathrm{h}}$ 和 $2.381 \times 10^{-9}\,E_{\mathrm{h}}$；这只是内部重复评价差，不能表述为电子结构方法的外部准确度。两条可移植归档各 33 个文件的大小与 hash 在本次只读核查中全部匹配，原始输出和 Hessian 可以追溯到冻结账本。

人工参与也属于结果的一部分：水链的采集逻辑曾经由开发者修复，随后采集已有计算事实而没有重新启动该计算；更早失败链保留。乙醇三节点记录各一次启动。历史 P7 中真实模型与模型收益验证仍标记为未运行，故不能由这两个选定成功案例估计 v2 的端到端自主成功率。相应成果是实际电子结构计算、局部科学支持和可复核归档，而不是无人干预计算能力。

表 7 v2 两条选定成功链的量化成果。自报耗时为 ORCA 三节点之和，不含人工等待、工作流和修复开销；不同分子与核数不能用于推导加速比。[H2]

项目	水 H_2O	乙醇 C_2H_6O
核数 / 总内存 / MaxCore	1 / 2048 MB / 1536 MB	4 / 2048 MB / 384 MB
实际成功计算节点	Opt、Freq、SP 各一次	Opt、Freq、SP 各一次
优化周期	4	11
优化末次评价电子能 / E_h	−76.418938721015	−155.002314096955
最终单点电子能 / E_h	−76.418938721035	−155.002314094574
首周期至优化末次降能 / mE_h	1.692636839	7.859199377
正振动模式数	3	21
正频率范围 / cm^{-1}	1653.249–3932.735	248.134–3837.522
Opt / Freq / SP 自报耗时 / s	11.457 / 10.358 / 2.328	62.390 / 31.142 / 5.323
三节点自报总耗时 / s	24.143	98.855
归档文件 hash/大小复核	33/33 匹配	33/33 匹配

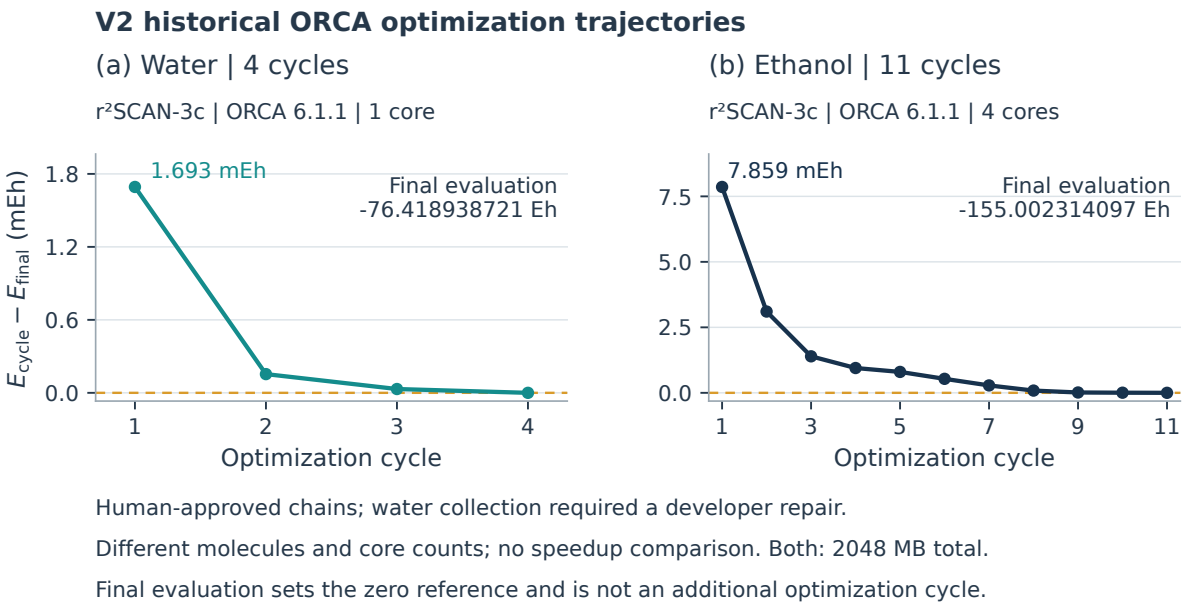


图 5 v2 历史优化收敛曲线。两条曲线各自减去对应的优化末次评价电子能，单位 mE_h；不同分子、初始构型与并行配置分别显示，不比较求解效率。原始行号、能量 token 和文件 hash 保存在历史数据 JSON。[H2]

6.7 v3：有限科学矩阵与模型参与的核心基准

6.7.1 固定科学矩阵的覆盖与数值结果

2026 年 9 月 24 日的 Scientific Matrix v1 包含 5 类任务与 6 个分子对象中显式启用的 11 个单元，11/11 单元通过，实际 ORCA 为 16 次、全部正常完成，模型调用为 0。[H3] 整体运行时间为 421.516 s。它是一组固定 Request/Plan 的开发者科学探针，验证组合执行与科学检查；没有启用的任务–分子组合不属于测试分母，也不代表失败。

水的三个正振动频率为 1653.24、3813.59、3932.75 cm^{-1}；CO_2 为 668.14、668.14、1362.20、

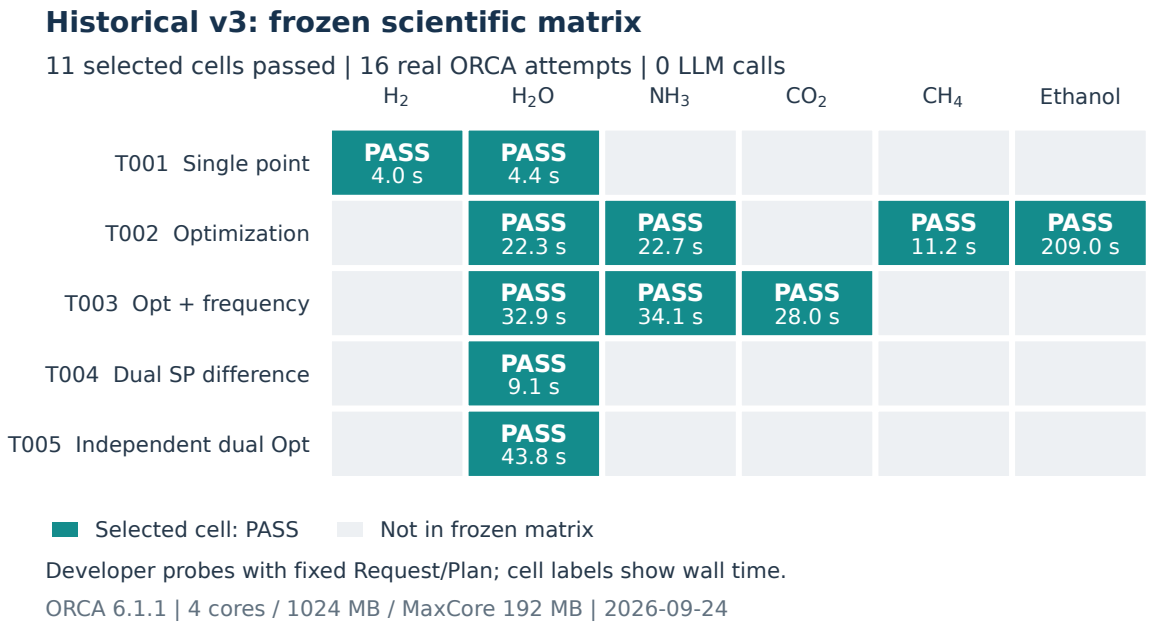


图 6 v3 固定科学矩阵的 11 个已启用单元。任务包括单点、优化、优化加频率、相同几何双单点能差及独立优化比较。格内耗时来自单元记录，整体时间另由总报告计量；浅灰格表示未纳入冻结矩阵。该批次有真实 ORCA、无真实 LLM。[H3]

表 8 v3 矩阵中可核查的优化终态。统一为气相 r^{2}SCAN-3c、零电荷、单重态；总资源为 4 核、1024 MB、MaxCore 192 MB/进程。频率结论仅来自对应的 Opt–Freq 单元，不由 Opt 单独赋予。[H3]

分子	优化周期	最终优化电子能 / E_h	本矩阵频率证据
H_2O	5	−76.418938720985	3 个正模式，局部极小值检查通过
NH_3	5	−56.541874067217	6 个正模式，局部极小值检查通过
CO_2	3	−188.570062871358	4 个正模式，局部极小值检查通过
CH_4	2	−40.494915367074	本矩阵该对象只执行优化
乙醇	36	−155.002354316872	本矩阵该对象只执行优化

2422.54 cm^{-1}。线性 CO_2 的五个外部零模式与四个振动模式被分别检查，不能机械套用非线性分子的六零模式规则。乙醇的 36 个优化周期之后还有一次末次能量评价，不应计为第 37 个周期，也不能仅凭其优化能量声称极小值。

同机固定输入在 9 月 23、24 日两次矩阵中有 13 个对应电子能结果在输出的 12 位小数精度上相同，三套振动频率也一致。本次对照可支持这些指定设置下的数值重复性；它不提供实验误差、独立高精度参考或对任意输入的精度保证。不同分子绝对能量也不构成相互之间的稳定性排序。

6.7.2 Benchmark 1.2 core 的分母、模型作用与成本

同日 Benchmark 1.2 core 的最终评分为 18/18，组成是 11 个固定科学题、5 个脚本化公开对话情境和 2 个名称解析题，其中 16 项实际涉及计算，另两项为澄清与拒绝。[H3] 驱动发送冻结话语，并在公开等待确认状态自动发送“确认”，经生产 `Agent.handle_message` 路径执行；没有直接注入 Request/Plan。这提供了有限对话任务上的模型参与证据，但不等同于开放任务的自由规

划评测。

表 9 v3 核心基准的量化结果。18/18 是所有适用维度的最终情境评分，包含不计算情境；23 次计算中含一次预设失败，不构成总体成功概率。[H3]

指标	记录值
最终通过 / 全部核心情境	18/18
实际计算情境 / 澄清或拒绝情境	16 / 2
真实模型调用	37
模型调用用途	Semantic 19；Answer 17；Repair 1
Intake / Planner 模型调用	0 / 0
输入 / 输出 / 总 tokens	140,953 / 6,985 / 147,938
ORCA 尝试	23：22 次成功、1 次预设受控失败
有界修复	1 次
PubChem / RDKit 外部操作	2 次请求 / 2 次几何生成
整体经过时间	667.547 s
记录的未请求计算 / 意外重算 / 执行安全违规	0 / 0 / 0

C005 通过 `MaxIter=1` 有意制造一次优化失败，再让模型参与一次有界修复。这是预先设计的故障恢复检验，不应写成自然故障发生率或以 22/23 估计总体可靠性。C004 最初的评分规则要求一次语义模型调用，随后允许生产系统的确定性拒绝路径，并对同一保存观察重评分；产品和 ORCA 事实没有重跑，最终 18/18 应附带这一校准说明。

基准评分检查了相应执行、输出、收敛与频率条件，未相对外部高精度参考评估数值误差。full 与 holdout 未运行，报告记录运行 HEAD 为 `f03c695f`，但当时实现与数据在工作树中，未保存完整 dirty-tree hash。因此，18/18 是特定有限基准的结果，不能扩展为未见任务成功率或对完整冻结源码的严格复现实验。本次只读核查共验证了相关记录中的 250 个登记文件及 56 份原始 Result；这些完整性核查不新增科学计算或扩大当时的科学资格。

6.8 跨版本成果的统一解读

表 10 各版本成果及可支持的结论。各行不是共同基准上的优劣排序，不能把分子链、情境和任务分母相加。

版本	本文纳入的量化成果	人工或既定工作流边界	结论范围
v2	两条成功链、6 个计算节点；水 3 个、乙醇 21 个正振动模式	逐节点批准；冻结协议；有开发者采集修复	小分子真实计算与可重解析证据
v3	科学矩阵 11/11；核心情境 18/18、37 模型调用	固定任务、脚本化话语与自动确认；一次评分校准	已定义范围内的组合任务、模型参与及受控修复
v4	历史自主与辅助正例；原稿七题批次 8 启动/7 正常、0/7 完整	现场生成代码、开放目标与更细的证据交付要求	执行链已有证据，完整跨任务可靠性仍需建立

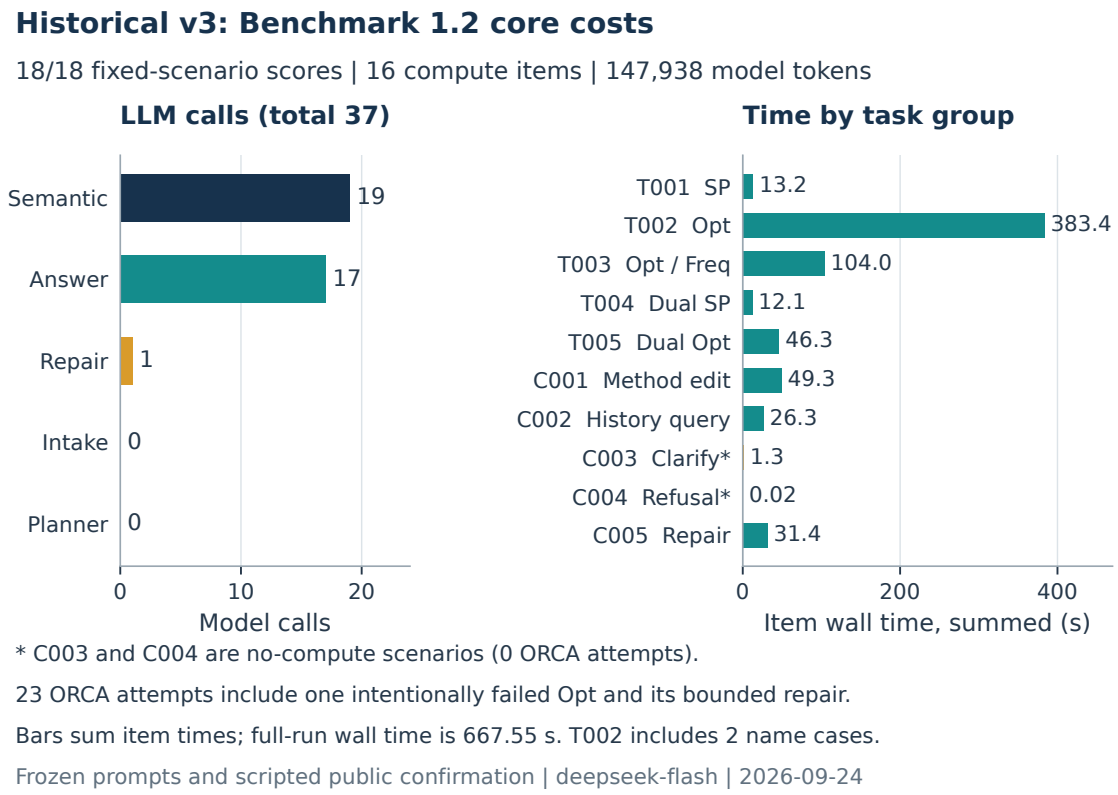


图 7 v3 核心基准的模型调用分工与任务组耗时。历史模型标识为 `deepseek-flash`，主要参与语义规范化和结果回答，Repair 有一次调用；不由 0 次 Intake/Planner 调用推断“没有模型参与”。各组分子、步骤数与对话长度不同，耗时不作为效率排名；C003/C004 分别为澄清与拒绝情境。[H3]

版本演进体现了评价对象的改变：v2 验证批准后的固定计算链，v3 在有限已定义任务上扩大组合与对话，v4 将更多任务算法交给现场代码，同时要求原目标、产物和检查贯通。v3 的 18/18 与 v4 的 0/7 没有共同任务分母，也缺少统一版本、模型和提示的受控对照；不能直接推导性能下降或上升。

历史成果可以支持已验证组件与方法设计的经验基础，但旧系统的科学检查、对象生命周期和运行资格不能自动迁入 v4。报告补充的是证据与分析，不恢复 v2 的数据库、Kernel/Reducer 或旧对话协议，也不改变 v4 的单协调者契约。后续若要证明版本收益，应冻结同一组用户目标、最低证据、输入与资源，分别测量完整交付、数值误差和成本。

7 讨论

7.1 从局部可执行到自主交付的断层

结果支持一个有限但清晰的判断：统一执行入口、隔离计算和部分生成代码路径已经获得真实证据；完整跨任务自主性仍有明显断层。早期乙醇正例说明模型可以在特定条件下完成有意义的路线，最新 T3/H1 说明新版本可以产生真实计算，但这些事实不能相互替代。开发阶段、模型、提示和任务暴露程度变化后，需要重新建立完整证据。

失败可分为四类。第一类是语言到契约的映射错误，如有效短引文被重复来源规则拒绝；第二类是已规范化条件未传到执行路由；第三类是修复和产物到目标的绑定丢失；第四类是反馈发现与容量失败，使后续行动缺少必要事实。它们不同于 SCF 不收敛，但同样决定最终科学任务能否完成。将所有失败归为“模型能力不足”或“量子化学难”都不足以指导修复。

7.2 闭环应由证据驱动，而非由角色数量定义

AutoDFT 为中间结果影响后续计划提供了方法参照，自主多参考研究则使态身份和任务覆盖成为必要评价维度。本文据此选择在一个循环内保留这些决策职责，通过 Tool 分隔执行权限。该选择符合项目单协调者约束，也有利于观察每次行动的授权和预算来源。

但单协调者并不天然更可靠。若上下文构建重复装入协议、历史正文与证据目录，一个循环同样可能在重要结果返回后失败；若条件 schema 与消费实现不同步，较少角色也不能防止错误。本文没有单 Agent 与多 Agent 的受控对照，因而将这一架构作为经过实现的设计取舍，而非已证明的性能优势。

7.3 科学资格应随证据增长，不能随文字升级

对于乙醇，独立 Hessian 和结构复核支持局部结论；生产输出仍保留原有资格状态。对于正己烷，四个单点只支持相应候选子集的电子能比较。对于 HCN，屏蔽张量存在只表明数据生成，尚未完成该任务要求的核对。三者展示了不同证据层次，也说明结果应注明“已执行到哪里、已检查什么、还有什么未知”。

开放观察可以扩展研究范围，但不能成为绕开科学要求的通道。若未来增加激发态、活性空间或更复杂性质，需要局部契约明确态身份、方法适用性、数值检查和参考依据。生成代码的自我声明、LLM 的解释流畅度以及正常退出码都不足以单独承担科学认证。

7.4 反馈开销与约束复杂度

资源限额限制最坏消耗，反馈质量则影响有限预算如何被使用。T4 的错误窗口没有及时呈现，使模型在错误文件之间往返；T3/H1 的上下文容量失败又发生在计算已有产出之后。由此可以提出后续可检验假设：统一当前错误入口、保留必要目标和可查询引用、去除已失效正文，有望提高同一预算内的有效行动比例。该假设仍需新冻结候选的真实运行检验，本文没有实测的 token 节省率。

另一方面，约束自身也可能成为失败来源。有效来源被错误拒绝或结构准备被要求提供无关科学条件，会降低可完成性；完全移除来源、条件和预算检查又会失去目标忠实性与执行边界。合理修复应减少重复表达和不一致消费，同时保留实际需求、科学检查、隔离与累计预算。

7.5 有效性威胁与当前限制

内部有效性首先受版本变化和开发者参与影响。历史正例、辅助案例和正式冻结测试应单列；v78 离线修复提交不替代新的真实实验。v2 的逐节点批准、v3 的自动确认脚本与固定题目、v4 的生成代码任务具有不同自主边界。外部有效性受任务数量、反复暴露、本地小体系和单一计算环境限制，本文未纳入真实集群证据。

构念有效性取决于指标定义。ORCA 启动、正常结束、观察来源通过和完整目标是不同计数单位；以其中一个代替其他指标会改变结论。成本则受到采样下界、供应商账单缺失和版本差异限制。安全方面，固定容器测试不能证明所有宿主、依赖或恶意脚本下均安全；每尝试磁盘硬配额仍未提供完整覆盖。

统计有效性也有限：七题各一次不足以估计稳定成功概率，四批不同候选的 28 次尝试更不是同版本重复；没有共同任务集和统一资源条件，不能与两篇重点论文的成功率或 MAE 排名。这些限制决定本文应被理解为研究原型的最终阶段报告和失败分析，而非产品成熟度认证。

8 后续研究与验证方案

v78/决策 0057 的修复包括统一短引文和值映射、按目标消费科学条件、同逻辑修复继承路线、去重反馈上下文和直接暴露内部 ORCA 失败，已另行提交。[E9] 这些变化针对已观察根因；已有离线回放不能把旧批次改判成功，也不能提前证明新版本的实际成本改善。本次报告扩充不对后续新候选作重新验收。

下一步应在修复稳定后冻结产品、提示、配置与评价脚本，按原任务逐项运行并保留全部结果。对每题同时报告计算前停止、实际启动、科学检查、部分完成和完整交付；对进入科学结果阶段的任务建立独立参考或确定性复核。对于扫描，检查实际几何角度、端点和必要图；对于环境比较，检查相同几何与环境条件；对于张量性质，检查单位、坐标和旋转关系。

之后再增加同版本重复和新的未暴露任务，观察可靠性分布，而非持续针对原七题调整后宣布通用。模型与规则的消融应在同任务、同预算下进行，区分代码生成、反馈组织和科学检查的贡献。未来多参考扩展则需先明确活性空间和态身份契约，再以可靠参考子集评价覆盖率和条件误差。上述内容是验证建议，不表示本次已经启动计算或获得新执行授权。

9 结论

本文以 BG6022-V4 为核心报告自主量子化学计算的系统设计，并补充 v2/v3 的量化历史。v2 为真实计算链与可重解析科学证据提供基础，v3 展示有限已定义任务上的组合执行、模型参与及有界修复，v4 进一步探索现场生成代码与开放目标。v4 通过七对象模型、唯一决策循环、统一 ORCA 入口、隔离执行和不可变证据建立可审查责任链。各版本成果均按实际方法、人工参与和评测口径保留，不自动继承为后续版本的验收结论。

最新七题产生真实计算而完整目标仍为 0/7，表明计算基础设施的可用性尚未转化为可靠的通用自主交付。来源、条件、修复绑定、上下文和错误证据之间的一致性是当前主要瓶颈。借鉴闭环 DFT 与自主多参考研究，后续进展应以同版本完整任务、独立科学检查、重复试验和新任务证据衡量。报告交付不代表项目能力已验收通过，当前结论与新修复均等待用户验收。

数据、代码与生成内容说明 主报告仓库为 https://github.com/az87988799/BG6022-v4，历史来源为对应的 `BG6022-v2` 与 `BG6022-v3` 仓库及本地归档。正文数值取自附录列出的记录，本次未新增科学计算。报告附带可复算图表 JSON、绘图脚本、来源核查清单和 LaTeX 源文件。部分历史 benchmark 原始报告未入旧仓库 Git，补充数据保存本地路径、hash 与提取规则，以披露其可获得性边界。图 1 使用内置 GPT Image 辅助生成，提示词与文件来源保存在报告目录；所有量化图由程序直接绘制。论文作者姓名、机构、资助与利益冲突声明未由用户提供，本文不代为编造。

参考文献

[1] P. Hohenberg and W. Kohn. Inhomogeneous Electron Gas. *Physical Review* **136**, B864–B871 (1964). doi:10.1103/PhysRev.136.B864.

[2] W. Kohn and L. J. Sham. Self-Consistent Equations Including Exchange and Correlation Effects. *Physical Review* **140**, A1133–A1138 (1965). doi:10.1103/PhysRev.140.A1133.

[3] S. Yao, J. Zhao, D. Yu, et al. ReAct: Synergizing Reasoning and Acting in Language Models. *The Eleventh International Conference on Learning Representations (ICLR)* (2023). OpenReview: WE_vluYUL-X; 预印本 doi:10.48550/arXiv.2210.03629.

[4] T. Schick, J. Dwivedi-Yu, R. Dessì, et al. Toolformer: Language Models Can Teach Themselves to Use Tools. *Advances in Neural Information Processing Systems* **36**, 68539–68551 (2023). doi:10.52202/075280-2997.

[5] N. Shinn, F. Cassano, A. Gopinath, et al. Reflexion: Language Agents with Verbal Reinforcement Learning. *Advances in Neural Information Processing Systems* **36**, 8634–8652 (2023). doi:10.52202/075280-0377.

[6] A. M. Bran, S. Cox, O. Schilter, et al. Augmenting large language models with chemistry tools. *Nature Machine Intelligence* **6**, 525–535 (2024). doi:10.1038/s42256-024-00832-8.

[7] D. A. Boiko, R. MacKnight, B. Kline, et al. Autonomous chemical research with large language models. *Nature* **624**, 570–578 (2023). doi:10.1038/s41586-023-06792-0.

[8] F. Neese, F. Wennmohs, U. Becker, et al. The ORCA quantum chemistry program package. *The Journal of Chemical Physics* **152**, 224108 (2020). doi:10.1063/5.0004608.

[9] F. Neese. Software Update: The ORCA Program System—Version 6.0. *WIREs Computational Molecular Science* **15**, e70019 (2025). doi:10.1002/wcms.70019.

[10] T. Tetenberg, H. Neugebauer, C. Plett, et al. ORCA Meets Python—The ORCA Python Interface OPI. *Journal of Chemical Theory and Computation* **22**, 4951–4967 (2026). doi:10.1021/acs.jctc.5c02141.

[11] P. Yang, Z. Zhang, Y. Li, et al. AutoDFT: A Closed-Loop Multi-Agent Framework for Autonomous DFT Calculations. *arXiv preprint*, arXiv:2605.26179v2 (2026), 2026 年 6 月 4 日版本. doi:10.48550/arXiv.2605.26179.

[12] V. C. Lee and J. M. Rondinelli. Can Autonomous LLM Agents Execute Multireference Quantum Chemistry Calculations? *arXiv preprint*, arXiv:2609.13357v1 (2026), 2026 年 9 月 11 日版本. doi:10.48550/arXiv.2609.13357.

[13] A. H. Larsen, J. J. Mortensen, J. Blomqvist, et al. The atomic simulation environment—a Python library for working with atoms. *Journal of Physics: Condensed Matter* **29**, 273002 (2017). doi:10.1088/1361-648X/aa680e.

[14] G. Pizzi, A. Cepellotti, R. Sabatini, et al. AiiDA: automated interactive infrastructure and database for computational science. *Computational Materials Science* **111**, 218–230 (2016). doi:10.1016/j.commatsci.2015.09.013.

[15] A. M. Ganose, H. Sahasrabuddhe, M. Asta, et al. Atomate2: modular workflows for materials science. *Digital Discovery* **4**, 1944–1973 (2025). doi:10.1039/D5DD00019J.

[16] N. M. O'Boyle, A. L. Tenderholt, and K. M. Langner. cclib: A library for package-independent computational chemistry algorithms. *Journal of Computational Chemistry* **29**, 839–845 (2008). doi:10.1002/jcc.20823.

[17] B. O. Roos, P. R. Taylor, and P. E. M. Siegbahn. A complete active space SCF method (CASSCF) using a density matrix formulated super-CI approach. *Chemical Physics* **48**, 157–173 (1980). doi:10.1016/0301-0104(80)80045-0.

[18] C. Angeli, R. Cimiraglia, S. Evangelisti, et al. Introduction of *n*-electron valence states for multireference perturbation theory. *The Journal of Chemical Physics* **114**, 10252–10264 (2001). doi:10.1063/1.1361246.

[19] E. R. Sayfutyarova, Q. Sun, G. K.-L. Chan, et al. Automated Construction of Molecular Active Spaces from Atomic Valence Orbitals. *Journal of Chemical Theory and Computation* **13**, 4063–4078 (2017). doi:10.1021/acs.jctc.7b00128.

[20] P.-F. Loos, M. Boggio-Pasqua, A. Blondel, et al. QUEST Database of Highly-Accurate Excitation Energies. *Journal of Chemical Theory and Computation* **21**, 8010–8033 (2025). doi:10.1021/acs.jctc.5c00975.

[21] J. P. Perdew, K. Burke, and M. Ernzerhof. Generalized Gradient Approximation Made Simple. *Physical Review Letters* **77**, 3865–3868 (1996). doi:10.1103/PhysRevLett.77.3865.

[22] A. D. Becke. Density-functional thermochemistry. III. The role of exact exchange. *The Journal of Chemical Physics* **98**, 5648–5652 (1993). doi:10.1063/1.464913.

[23] C. Lee, W. Yang, and R. G. Parr. Development of the Colle–Salvetti correlation-energy formula into a functional of the electron density. *Physical Review B* **37**, 785–789 (1988). doi:10.1103/PhysRevB.37.785.

[24] F. Weigend and R. Ahlrichs. Balanced basis sets of split valence, triple zeta valence and quadruple zeta valence quality for H to Rn: Design and assessment of accuracy. *Physical Chemistry Chemical Physics* **7**, 3297–3305 (2005). doi:10.1039/B508541A.

[25] S. Grimme, J. Antony, S. Ehrlich, et al. A consistent and accurate *ab initio* parametrization of density functional dispersion correction (DFT-D) for the 94 elements H–Pu. *The Journal of Chemical Physics* **132**, 154104 (2010). doi:10.1063/1.3382344.

[26] E. Runge and E. K. U. Gross. Density-Functional Theory for Time-Dependent Systems. *Physical Review Letters* **52**, 997–1000 (1984). doi:10.1103/PhysRevLett.52.997.

[27] M. Cossi, N. Rega, G. Scalmani, et al. Energies, structures, and electronic properties of molecules in solution with the C-PCM solvation model. *Journal of Computational Chemistry* **24**, 669–681 (2003). doi:10.1002/jcc.10189.

[28] C. Bannwarth, S. Ehlert, and S. Grimme. GFN2-xTB—An Accurate and Broadly Parametrized Self-Consistent Tight-Binding Quantum Chemical Method with Multipole Electrostatics and Density-Dependent Dispersion Contributions. *Journal of Chemical Theory and Computation* **15**, 1652–1671 (2019). doi:10.1021/acs.jctc.8b01176.

[29] P. Pracht, F. Bohle, and S. Grimme. Automated exploration of the low-energy chemical space with fast quantum chemical methods. *Physical Chemistry Chemical Physics* **22**, 7169–7192 (2020). doi:10.1039/C9CP06869D.

[30] M. D. Wilkinson, M. Dumontier, I. J. Aalbersberg, et al. The FAIR Guiding Principles for scientific data management and stewardship. *Scientific Data* **3**, 160018 (2016). doi:10.1038/sdata.2016.18.

[31] FACCTs. *ORCA Python Interface (OPI) 2.0 Documentation*. 官方技术文档，访问日期：2026 年 10 月 21 日. https://www.faccts.de/docs/opi/2.0/docs/.

[32] S. Grimme, A. Hansen, S. Ehlert, and J.-M. Mewes. r^{2}SCAN-3c: A "Swiss army knife" composite electronic-structure method. *The Journal of Chemical Physics* **154**, 064103 (2021). doi:10.1063/5.0040021.

A 项目证据索引

E1–E9 的相对路径以 v4 仓库为根目录；H2/H3 的路径分别以 v2/v3 为根目录。E1/E2 为契约，E3–E8 为原稿选取的历史实验，E9 为 v78 离线修复。它们与历史项目记录不计入学术文献数量。原稿来源 hash 保留于 `source-manifest.json`，新增历史提取见 `historical-v2-evidence.json` 与 `historical-v3-evidence.json`；文献核查见 `sources-bibliography.json`。

编号	仓库证据与用途
E1	`docs/ORCA-Agent-Project-Blueprint.md`。单循环、七对象、目标独立、结果资格、预算、执行边界与评价要求。
E2	`docs/CODE-AS-TOOLS-IMPLEMENTATION-PLAN.md`；`docs/decisions/0031-code-as-tools-contract.md`。代码作为工具的契约与实施范围。
E3	`docs/acceptance/code-as-tools-step2-linux/report.md`；`docs/decisions/0033-local-linux-container-execution.md`。固定 Linux 环境、隔离检查和开发者真实 ORCA 探针。
E4	`docs/acceptance/code-as-tools-step3/report.md`；其 `validation/live035-independent-scientific-audit.json` 与 `validation/live035-pro-autonomous-optfreq.json`。乙醇自主路线和独立开发科学复核。
E5	`docs/acceptance/code-as-tools-step5-completion/report.md`；同目录 `validation/finalaudit.json`。正己烷有限候选与协助交付边界。
E6	`docs/acceptance/code-as-tools-step7/report.md`；`docs/acceptance/code-as-tools-step7-refreeze-1/report.md`。前两批正式测试。
E7	`docs/acceptance/code-as-tools-step7-refreeze-2/report.md`；`docs/acceptance/workflow-simplification/report.md`。第三批与对应离线历史。
E8	`docs/acceptance/code-as-tools-step7-refreeze-3/report.md`；同目录 `validation.json`；`docs/acceptance/workflow-simplification-2/report.md`。最新七题、成本、冻结、归档与中止的离线回归。
E9	`docs/decisions/0057-repair-evidence-driven-workflow.md`；`docs/acceptance/workflow-root-repair/report.md`。原稿时仍在开发的 v78 修复已于 `2e872a18` 提交；离线回放不替代新的真实自主成功证据。
H2	v2：`docs/P6_ACCEPTANCE.md`；`docs/evidence/p6-water/packet/` 与 `docs/evidence/p6-ethanol-4core-2048mb/packet/`。两条真实计算链、原始输出、Hessian、批准与可移植归档。
H3	v3：`docs/evidence/benchmark1.2.md`；`benchmarks/results/benchmark12-core-live-20260924/` 与 `benchmarks/results/scientific-v1-live-20260924/`。核心 18 项与 11 单元科学矩阵；原始报告位于本地忽略目录。

B 复现报告与核查规则

本报告采用 UTF-8、`ctexart` 与 Fandol 字体。在报告目录执行 `xelatex main.tex` 两次即可编译；参考文献直接内嵌，无需 BibTeX/Biber。量化图已附 PDF，普通编译不需要 Python 或网络。

图表复算命令和可选依赖见 `figures/README.md`。脚本仅分析随包数据，不启动模型、ORCA 或容器；历史版本、辅助案例与正式评测保持分开计数。

审阅时可按以下顺序核查：先确认冻结候选与实验范围，再检查实际启动和原始文件，随后核对输出科学检查，最后对照原目标与必需交付。对于尚无独立参考的任务，应保留该缺项；对于开发中修复，应要求新冻结证据，不能把计划和授权当作执行结果。